

# Tecniche di Protezione del Software

Massimo Perego

## Contents

<b>1</b>	<b>Spatial Memory Errors</b>	<b>3</b>
1.1	Memory Layout . . . . .	4
1.1.1	Stack . . . . .	6
1.2	Stack-based Overflow . . . . .	8
1.2.1	Code Injection . . . . .	9
1.3	Heap . . . . .	11
1.3.1	Heap vs Stack . . . . .	11
1.3.2	Heap Chunk . . . . .	12
1.3.3	Allocare e deallocare memoria . . . . .	13
1.4	Heap Overflow . . . . .	14
1.4.1	Unlink . . . . .	14
1.4.2	Exploit “Naive” . . . . .	15
1.4.3	House of Force . . . . .	16
<b>2</b>	<b>Temporal Memory Errors</b>	<b>20</b>
2.1	Use After Free UAF . . . . .	20
<b>3</b>	<b>Memory Safety and Type Safety</b>	<b>22</b>
3.1	Memory Safety . . . . .	22
3.1.1	Spatial safety . . . . .	23
3.1.2	Temporal Safety . . . . .	24
3.2	Type Safety . . . . .	25
3.3	Avoiding Exploitation: Other strategies . . . . .	27
<b>4</b>	<b>Return Oriented Programming ROP</b>	<b>30</b>
4.1	Blind ROP . . . . .	33
<b>5</b>	<b>Control Flow Integrity CFI</b>	<b>36</b>
5.1	Costruzione del Control Flow . . . . .	38

5.2	In-Line Monitor . . . . .	40
<b>6</b>	<b>Vulnerabilities Detection</b>	<b>42</b>
6.1	Symbolic Execution . . . . .	44
6.1.1	Concolic Execution . . . . .	49
<b>7</b>	<b>Fuzz Testing</b>	<b>50</b>
7.1	Fuzzer Architecture . . . . .	51
7.1.1	Sanitizers . . . . .	54

# 1 Spatial Memory Errors

Ci concentriamo su linguaggi low level (e.g., C), i quali tendono a crashare in caso di errori (come buffer overflow), ma un attaccante può **sfruttare le vulnerabilità** per ottenere informazioni (e.g., Heartbleed, bug SSL che permetteva di leggere tutta la memoria del programma, che su SSL insomma, peso), corrompere memoria, fino ad arbitrary code execution (la macchina comincia ad eseguire altro, diventa una “weird machine”), ecc.

Il crash (ovvero **segfault**), se analizzato può portare ad un attacco, anche se non tutti i casi sono exploitabili (molti sì).

Questo tipo di bug hanno una lunga storia e sono tuttora presenti, e lo saranno finché C e C++ saranno usati. Inoltre è utile studiare l’evoluzione del bug stesso, assieme alle difese create per contrastarlo. Alcune caratteristiche di un attacco/difesa possono risultare presenti anche in altri attacchi.

Inoltre, solitamente, l’attacco è molto più semplice della difesa. Per l’attacco mi basta un punto, per la difesa devo essere sicuro di aver coperto tutti i possibili punti di attacco, senza degradare troppo le performance.

I sistemi C e C++ sono ancora molto presenti e spesso sono parte di sistemi critici come:

- OS, Kernel e relative utilities
- Server che richiedono alte prestazioni (Apache httpd, nginx, MySQL, redis)
- Sistemi embedded (risorse limitate, le performance sono importanti)

La prima versione di buffer overflow funzionante è del 1988: Morris Worm, per poi dare inizio ad una catena di exploit che permettono la compromissione della macchina stessa (a diversi livelli), in qualsiasi caso con un impatto significativo.

## 1.1 Memory Layout

Dobbiamo sapere come un programma viene caricato in memoria, in quali zone e di conseguenza cos'è lo stack e quali sono gli effetti delle chiamate a funzione. Parleremo del modello Linux **x64**, anche se il concetto dell'attacco è universale l'implementazione può cambiare in base a dettagli tecnici (architectural dependent).

**Ogni processo** ha un proprio **layout di memoria**, con indirizzi che vanno da `0x00000000` a `0xffffffff` (per 32 bit, con 64 sarebbero troppo lunghi da scrivere), quindi 4GB di indirizzamento totali.

Linux divide:

- 1GB per il sistema operativo, dall'alto
- 3GB per le applicazioni

Di conseguenza il primo indirizzo valido per il programma è `0xbfffffff`, sopra c'è il kernel.

Il **loader carica in memoria** un **processo** quando questo viene chiamato, occupando la page table ed allestendo la memoria per l'uso del programma.

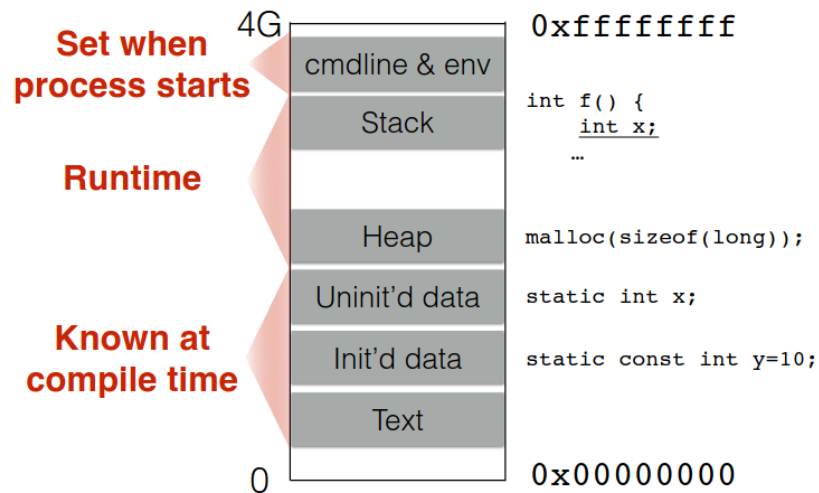
Il loader divide la memoria (tra quella adibita al programma, i 3GB di prima) in sezioni:

- **Text** per memorizzare il codice del programma
- Zone per dati inizializzati (**Data**) e non (Block Started by Symbol **BSS**)

Queste sono **conosciute a compile time**, mentre

- **Stack**
- **Heap**

Sono **dinamiche** e permettono la gestione del programma.



Stack e Heap quindi sono zone dinamiche che **crescono in direzioni opposte** (stack verso il basso).

Nell'heap ci sono le allocazioni dinamiche effettuate dal programmatore stesso (`malloc` e simili), mentre lo **stack** viene **gestito dal compilatore** per memorizzare cose come le chiamate a funzione.

### 1.1.1 Stack

All'interno dello stack viene gestita l'esecuzione del programma. Gli **indirizzi dello stack crescono verso il basso**, partendo da `0xbfffffff` e scendono. Questo rende possibile l'attacco di buffer overflow stack based, nel modo attualmente esistente.

Man mano che viene allocata memoria, lo stack alloca spazio dall'alto verso il basso. **Push** decrementa il valore dell'indirizzo, **Pop** lo aumenta.

**Stack Pointer:** Su architetture Intel, si tratta del **registro** che tiene conto dell'**indirizzo a cui è arrivato lo stack**, il valore dello spazio allocato più in basso (ultimo valore allocato, da dove posso ricominciare ad allocare).

Il compilatore utilizza lo stack quando vengono chiamate le funzioni, **nel momento in cui avviene una chiamata a funzione**:

- viene effettuata la **push** (istruzione macchina) dei parametri della funzione sullo stack
- l'istruzione macchina **call** viene chiamata, portando l'esecuzione all'indirizzo di memoria del codice della funzione
- la **call** effettua anche la **push** sullo stack dell'indirizzo di ritorno di una funzione, ovvero da dove proseguire l'esecuzione al termine della funzione

Dopo queste istruzioni comincia l'esecuzione della funzione. All'**interno dello stack** vengono **memorizzate le variabili locali**, quindi viene effettuata una **push** di queste variabili all'interno dello stack.

Al termine dell'esecuzione ci sarà un'istruzione **ret** che fa tornare l'**esecuzione all'indirizzo puntato dal return address** memorizzato in precedenza sullo stack (anche senza **return** esplicito, serve a continuare l'esecuzione del programma dopo la funzione).

La funzione di **ret**:

- libera la zona dedicata alle variabili locali, **pop** di tutte le variabili memorizzate sullo stack
- carica nell'Instruction Pointer (o Program Counter, registro che tiene traccia dell'istruzione da eseguire) il valore del return address (indirizzo della prossima istruzione che deve eseguire il processore)

Bisogna deallocare anche i parametri allocati sullo stack ma chi lo effettua dipende dalla calling convention del compilatore, quindi può farlo il chiamato o il chiamante (i.e., il **pop** di quei valori verrà effettuato prima o dopo il **ret**).

In ordine, dall'alto verso il basso, all'interno dello stack saranno presenti:

- Parametri
- Return address
- Variabili locali

## 1.2 Stack-based Overflow

Esempio di bug:

```
1 void f (par){  
2     char buf[10];  
3     strcpy(buf, par);  
4 }
```

La funzione **non controlla dimensioni di sorgente e destinazione**, quindi cosa succede se l'**elemento da copiare è più grande della memoria** che gli è stata **allocata** (ovvero la dimensione del buffer destinazione)?

Lo **stack** sarà **composto da**:

- parametri della funzione, **par** in questo caso
- return address
- variabili locali, qui solo il buffer destinazione

Se la dimensione del buffer da copiare è maggiore del buffer allocato il programma **andrà a sovrascrivere i valori precedenti nello stack** (lo stack alloca dall'alto verso il basso, ma gli indirizzi del buffer vanno dal basso verso l'alto, l'indice 1 è più in basso dell'indice 8, per mantenere coerente l'aritmetica con i puntori, I guess).

Il valore sopra il buffer nello stack è il return address, che porterà a tornare ad un indirizzo casuale se sovrascritto, portando ad un **segfault**.

Non c'è un controllo che limiti la scrittura alla dimensione del buffer, portando a sovrascrivere altre parti dello stack.



### 1.2.1 Code Injection

Come possiamo sfruttare questa situazione? Tramite buffer overflow posso avere il controllo sul return address; control flow hijacking.

Per arrivare ad **eseguire codice arbitrario** devo

- definire il codice
- iniettarlo in memoria
- cambiare il valore del return address in modo che punti a quella zona di memoria

**Definire il codice:** Il processore legge solamente stringhe di byte che corrispondono alle istruzioni da eseguire. Noi dobbiamo costruire un bytestream a partire da del codice sorgente che vogliamo eseguire. Un bytestream che chiama `/bin/bash` diventa uno shellcode.

Dobbiamo forgiare un bytestream adatto alle nostre esigenze, manualmente prendendolo da del codice eseguito o tramite tool appositi (più facile solitamente).

**Injection Vector:** Per metterlo in memoria, il posto ideale sarebbe il **buffer** che abbiamo **già a disposizione**. L'**input** viene **copiato nel buffer**, il quale è sullo stack. Quindi inserendo il bytestream all'interno dell'input posso inserirlo in memoria all'interno del buffer.

Dobbiamo **costruire un input** che fa partire l'esecuzione del codice voluto (chiamato injection vector). Sarà quindi composto dal **bytestream del codice** (e.g., shellcode) e dal **valore che sovrascriverà il return address**, ovvero l'indirizzo del buffer (come trovarlo?).

Nell'esempio sopra ci saranno 10 byte per lo shellcode (dimensione allocata per il buffer) e 4 byte per il return address (considerando architetture a 32 bit).

In questo modo, quando il programma torna dalla funzione, porrà nel program counter l'indirizzo del buffer, contenente il bytestream forgiato da noi. La sequenza di istruzioni posta nel buffer sarà quindi interpretata come codice. Abbiamo dirottato il control flow, portando all'esecuzione di codice arbitrario.

**Spatial memory error:** Stiamo “mischiando” dati dell’utente e control channel (comandi di controllo), problematica comune a più vulnerabilità e possibili ambiti. Sovrascriviamo nello spazio dei caratteri di controllo. L’esecuzione di codice arbitrario avviene al ritorno della funzione vulnerabile.

Adesso ci sono protezioni che bloccano esecuzione di codice all’interno dello stack, non è una zona di memoria che dovrebbe contenere codice (anche se ci sono anche casi particolari) e l’esecuzione di codice presente in zone di memoria simili è bloccata.

## 1.3 Heap

### 1.3.1 Heap vs Stack

Lo **stack** è principalmente gestito dal compilatore per allocazioni **statiche** della memoria, conosciute a compile time. Inoltre tutti i metadati utili al programma sono memorizzati sullo stack. Un esempio di metadato è il return address per il ritorno di una funzione.

Questo è solitamente nascosto al programmatore, se la dimensione dei dati non è nota a priori viene usato l'**heap**, una memoria comandata (allocazione e liberazione) dal programmatore tramite funzioni di libreria. Generalmente più lenta ed a **gestione manuale**. Solitamente usato per oggetti, structs ed in generale elementi più grandi.

Lo stack cresce dall'alto verso il basso (indirizzi), mentre l'heap cresce dal basso verso l'alto. Una **push** sullo stack sposta il **rsp** verso il basso (e, di conseguenza, la **pop** verso l'alto). In caso di un utilizzo troppo elevato di memoria si possono “incontrare” le due zone (hai finito la memoria).

La vulnerabilità già vista sullo stack nasce dal “mischiare” dati inseriti dall'utente con metadati che permettono di alterare il flusso di controllo del programma.

Le due funzioni principali per gestire la memoria nell'heap sono:

- **malloc(size)**: restituisce un puntatore ad una zona di memoria con dimensione **size**
- **free(ptr)**: dato un puntatore, libera la zona di memoria associata

Anche nell'heap sono presenti metadati, e di conseguenza la possibilità di sovrascriverli, portando a possibili vulnerabilità.

**Allocatori:** Definiti nelle librerie di sistema, per gestire le zone di memoria allocate servono comunque dei metadati. L'allocatore gestisce i propri dati all'interno dell'heap stesso (problema di canale).


### 1.3.2 Heap Chunk

**Heap Chunk:** Struttura dati per la memoria nell'heap. Struttura:

```
1 struct malloc_chunk {
2     INTERNAL_SIZE_T      prev_size;
3     INTERNAL_SIZE_T      size;
4
5     struct malloc_chunk*  fd;
6     struct malloc_chunk*  bk;
7
8     struct malloc_chunk*  fd_nextsize;
9     struct malloc_chunk*  bk_nextsize;
10 };
```

In ordine, i parametri sono:

- **prev\_size**: dimensione della zona di memoria precedente, usato solo se il chunk è libero
- **size**: dimensione della zona di memoria occupata da questo chunk, overhead compreso
- **fd**, **bk**: puntatori alle zone di memoria precedenti e successive nella lista di chunk liberi (e di conseguenza presenti solo se il blocco è libero)
- **fd\_nextsize**, **bk\_nextsize**: puntatori alle dimensioni degli elementi adiacenti nella lista di chunk liberi (usati solo se il chunk è libero)



I chunk occupati contengono solo **size** e i dati. Il puntatore di ritorno ottenuto tramite **malloc** punta all'inizio della zona contenente i dati.

### 1.3.3 Allocare e deallocare memoria

**Allocazione:** All’inizio dell’esecuzione si ha un top chunk, che rappresenta tutta la grandezza dell’heap. Si ha un puntatore al top chunk chiamato `av_top`; inizialmente questo puntatore coincide con la base della memoria. In seguito ad una `malloc`, viene allocata la zona di memoria richiesta, restituendo i relativi puntatori, e di conseguenza `av_top` viene spostato “sopra” al blocco allocato, deve puntare sempre alla zona di memoria “rimanente”; il top chunk decresce in seguito all’allocazione.

**Deallocazione:** Oltre allo spazio libero del top chunk sono presenti delle liste di free chunk, una per ogni dimensione di chunk liberi (se posso occupare la memoria esatta lo faccio, serve a ridurre la frammentazione). Quando viene richiesta un’allocazione, prima cerca se c’è una zona di memoria “grande giusta” (o poco più, se mi servono 256 byte cerco nella lista di blocchi liberi da 256 byte), se non c’è una zona adatta nelle liste di chunk liberi allora prende la memoria dal top chunk.

Nel caso in cui due chunk adiacenti diventino liberi, vengono collassati in uno solo e lo inserisce nella lista rilevante.

#### Allocazione:

- Richiesta di memoria (`malloc`)
- Ricerca di un blocco libero (prima dalle liste, eventualmente si usa il top chunk)
- Aggiornamento della struttura di gestione (metadati)
- Restituzione del puntatore

#### Deallocazione:

- Richiesta di rilascio (`free`)
- Il blocco viene marcato come libero
- Coalescenza di blocchi adiacenti (se presenti, si fondono blocchi liberi adiacenti in uno solo)
- Aggiornamento della struttura di gestione

## 1.4 Heap Overflow

### 1.4.1 Unlink

Quando viene effettuata una allocazione bisogna aggiornare i puntatori, il nodo occupato va “sganciato” dalla lista (doppiamente concatenata) di blocchi liberi, e di conseguenza i puntatori del blocco successivo e precedente vanno aggiornati (sai come si rimuove un elemento da una lista dai). La procedura è

```
1 void unlink(malloc_chunk *P, malloc_chunk *BK,  
2             malloc_chunk *FD) {  
3     FD = P->fd;  
4     BK = P->bk;  
5     FD->bk = BK;  
6     BK->fd = FD;  
7 }
```

Dove:

- P nodo da eliminare
- BK nodo precedente
- FD nodo successivo

“Stacco” il nodo da eliminare facendo puntare il puntatore **bk** del nodo successivo al nodo precedente e viceversa.

### 1.4.2 Exploit “Naive”

Se non è presente nessun controllo durante le scritture, una write troppo grande può andare a sovrascrivere i chunk (liberi o occupati) superiori, meta-dati compresi.

Nello specifico, posso sovrascrivere il `FD->bk` e `P->bk`, rispettivamente con l’indirizzo di un return address e un indirizzo di un buffer (injection vector).

```
1      FD->bk = return address address;  
2      FD = P->fd;  
3      BK = P->bk = address of the buffer;  
4      FD->bk = BK;
```

Partendo da un heap con dei chunk liberi e la relativa lista, facendo overflow in un chunk occupato sottostante si può sovrascrivere il puntatore `bk` di due chunk vuoti con indirizzi determinati dall’attaccante (rispettivamente, un blocco con inizio di un buffer con codice malevolo, il blocco dopo con l’indirizzo del return address di una funzione).

Quando il programma andrà ad allocare il primo dei blocchi con i valori sovrascritti dovrà rimuoverlo dalla lista di blocchi liberi, quindi eseguire la procedura di unlink: il `bk` del blocco “sganciato” punta al buffer contenente qualcosa (e.g., shellcode, inizio di un buffer controllato dall’attaccante, in qualsiasi modo), mentre il `bk` blocco successivo punta al return address di una funzione, il quale verrà sovrascritto con l’indirizzo del buffer (procedura di unlink), portando il programma ad eseguire il codice all’interno del buffer una volta che il programma dovrà seguire il return address sovrascritto.

Questo exploit è stato patchato controllando che `FD` e `BK` puntino effettivamente l’uno all’altro, non si può più sparare allo stack.

### 1.4.3 House of Force

Dopo la patch per la correzione dell'unlink sono nate nuove tecniche per sfruttare l'heap overflow, le principali si chiamano:

- The House of Prime
- The House of Mind
- **The House of Force**
- The House of Lore
- The House of Spirit
- The House of Chaos

Verrà mostrata solo la House of Force, spiegazioni ed esempi per le altre possono essere trovate [a questo indirizzo](#). Ognuna di queste sfrutta diverse funzionalità dell'allocatore per attuare un attacco.

Tutte le tecniche citate hanno delle **condizioni per poter essere utilizzate**, la sola presenza della vulnerabilità non vuol dire che possa essere sfruttata.

Il **fuzzing** è il processo di trovare vulnerabilità nel programma, cercando crash del programma. Dopo aver trovato la vulnerabilità (i.e., il crash) bisogna analizzare se nel punto del programma che causa il crash ci sono le condizioni per un attacco vero e proprio, c'è da capire su che possibile vulnerabilità bisogna concentrarsi.

Un possibile ambito di ricerca sono gli AEG Automatic Exploit Generation: software per costruire in automatico attacchi a partire da possibili vulnerabilità (crash).



Esempio di programma vulnerabile ad House of Force:

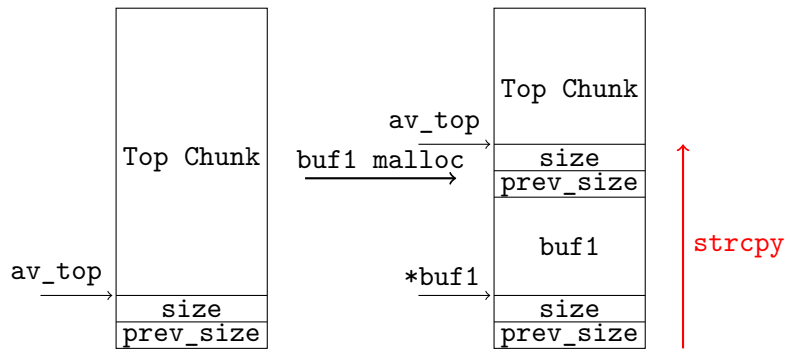
```
1 char *buf1, *buf2, *buf3;
2
3 buf1 = malloc(256);
4 strcpy(buf1, argv[1]);
5
6 buf2 = malloc(strtoul(argv[2], NULL, 16));
7 buf3 = malloc(256);
8 strcpy(buf3, argv[3]);
9
10 free(buf3);
11 free(buf2);
12 free(buf1);
```

Condizioni necessarie per questo exploit:

- avere una prima malloc su un numero arbitrario di byte (fisso, non importante, buf1 nell'esempio)
- avere una strcpy() sul buffer precedente (buf1)
- avere un'altra malloc comandata dall'attaccante, i.e., la cui dimensione è definita in modo dinamico tramite input, in qualche modo (buf2)
- avere un'altra malloc non comandata dall'attaccante, in cui l'attaccante può scrivere (anche in modo controllato, basta poter scrivere)

Al termine del programma ci saranno le free.

Cosa succede sull'heap quando queste tre condizioni sono soddisfatte?



Quindi possiamo arrivare a sovrascrivere la **size** del top chunk, permettendo di dire al programma quanto spazio libero rimane all'interno. Questa è il primo problema: metadato size del top chunk modificabile dall'attaccante. A questo punto posso "incrementare" la memoria dell'heap (dimensione di **size**) fino a **tutta la memoria del processo indirizzabile**, la **size** è determinata unicamente in modo software. Posso andare ad indirizzare nell'intera memoria del processo.

Una volta "allargato tutto", l'attaccante può andare in un punto arbitrario della memoria da sovrascrivere. L'heap adesso include stack, .text ed in generale tutta la memoria. Posso sovrascrivere una zona di memoria arbitraria con un qualsiasi valore. Ad esempio, sovrascrivendo un **return address** sullo stack.

Abbiamo ingannato l'allocatore per **includere lo stack nello spazio indirizzabile dall'heap**, permettendoci di sovrascrivere una zona di memoria arbitraria.

La seconda **malloc** ha un'ampiezza comandata dall'attaccante, il che ci permette di **raggiungere la base dello stack**, dove c'è il **return address** che si vuole sovrascrivere (questa è una dimensione variabile,  $\Delta$  tra posizione dell'**av\_top** e posizione del **return address**, da calcolare).

Dopo una `malloc` di dimensione  $\Delta$ , l'`av_top` sarà nello stack, la terza allocazione di dimensione  $n$  (fissa), partirà dall'`av_top` (in questo momento stiamo presupponendo non ci siano liste libere, altrimenti bisogna stare un po' più attenti) e quando comincio a scrivere in quest'ultimo buffer (ultima `strcpy`, comandata dall'attaccante) starò sovrascrivendo il `return address`, magari con un indirizzo di una zona di memoria il cui contenuto è controllato dall'attaccante (anche nell'heap, generalmente la zona dati non è eseguibile, ma ci sono dei casi in cui potrebbe esserlo).

**TL;DR:** Inganniamo l'allocatore nel pensare che il top chunk sia più grande di quanto non sia realmente, tramite overflow, per poi andare a sovrascrivere una zona di memoria arbitraria in una scrittura successiva.

## 2 Temporal Memory Errors

Le vulnerabilità viste fin'ora si basavano su un “problema” nello spazio relativo alla memoria (overflow di qualcosa), invece, le vulnerabilità basate sul rompere la temporal memory si focalizzano su una sequenza di esecuzione in ordine temporale, la **vulnerabilità si presenta in un certo istante di esecuzione** del programma, ovvero in uno stato specifico in cui il programma si trova.

Sono difficili da individuare con una revisione manuale del codice dato che serve conoscere la sequenza esatta di allocazione e deallocazione durante l'esecuzione del programma, difficilmente individuabile su codice complesso.

### 2.1 Use After Free UAF

Una Use-After-Free accade quando si **usa un puntatore che è stato precedentemente liberato** (dereferenziazione di un puntatore che punta ad una zona di memoria liberata, dangling pointer).

Esempio:

```
1 char *a , *b; int i;
2
3 a = malloc(16) ;
4 b = a + 5;
5 free(a) ;
6
7 b[2] = 'c' ; /* use after free */
8 b = retptr( ) ;
9 *b = 'c' ; /* use after free */
```

Conoscere l'insieme di puntatori che puntano ad un oggetto, senza una struttura dati come il garbage collector, non è un problema semplice (**aliasing problem**). Un analizzatore statico solitamente non riesce a trovare tutti gli aliasing, inoltre possono esserci puntatori definiti dinamicamente sulla base dell'oggetto.

Per avere una UAF devo individuare:

- una allocazione
- una deallocazione
- una dereferenziazione su un qualcosa di deallocato

Dopo averla individuata bisogna sfruttarla, tramite la funzione dell'allocatore che effettua la ricerca nelle liste di blocchi liberi un elemento della esatta grandezza richiesta, i.e., se la grandezza è giusta, riallocherà la zona allocata in precedenza.

Se c'è la possibilità, dopo la deallocazione, di eseguire una `malloc` di dimensione e valori controllati, il dangling pointer precedente punterà ai dati scritti dall'attaccante (quelli che sono rimasti nella zona deallocata e successivamente re-allocata).

La UAF è la vulnerabilità più frequente *in natura*, più difficile da scovare e spesso permette di arrivare a esecuzione di codice arbitrario.

### 3 Memory Safety and Type Safety

Tutti gli errori descritti nelle sezioni precedenti nascono da un **utilizzo errato della memoria**, nei linguaggi che lo permettono. Utilizzare **linguaggi memory safe** permetterebbe di evitare le problematiche descritte precedentemente, ma il degrado delle performance potrebbe non essere accettabile per alcuni casi d'uso.

Memory safety e type safety sono due proprietà intrinseche ad alcuni linguaggi di programmazione che permettono di bloccare la possibilità di effettuare gli attacchi descritti in precedenza.

Le difese possono essere a **livello** di:

- **compilatore**: come le canary, usate per rilevare una eventuale sovrascrittura del return address
- **sistema operativo**: come il Address Space Layout Randomization ASLR, che impedisce di sapere le posizioni esatte dei valori in memoria
- **architetturale**: componenti hardware che permettono di bloccare gli attacchi

Per contrastare ASLR sono nati gli attacchi Return Oriented Programming ROP, e per contrastare questi esiste la Control Flow Integrity CFI (controllo sulle transizioni del programma, se va “fuori dagli schemi” la transizione è bloccata, come ad esempio cambiando il return address).

#### 3.1 Memory Safety

Sicurezza della memoria, si tratta di una proprietà fondamentale di alcuni linguaggi (detti memory safe). Un programma scritto in un linguaggio memory safe:

- Permette di creare puntatori solo attraverso alcuni mezzi standard; si vogliono intercettare i punti di creazione dei puntatori
- Permette di usare puntatori solo per accedere a memoria che “appartiene” a quel puntatore; un puntatore che appartiene ad una zona di memoria deve accedere effettivamente a quella zona di memoria

Combina le idee di temporal safety (accedere solo a memoria attualmente allocata/valida) e spatial safety (accedere solo a memoria valida).

### 3.1.1 Spatial safety

Ci permette di far valere la proprietà di sicurezza spaziale della memoria, ovvero andare a vedere che un puntatore non vada a puntare oltre una zona di memoria stabilita.

**Fat Pointers:** Un puntatore non è più “solo un puntatore”, ma diventa una tripla  $(p, b, e)$  dove:

- $p$  è il puntatore effettivo
- $b$  è la base della zona di memoria a cui può accedere
- $e$  è l'estensione/limite della zona a cui può accedere

L'accesso è permesso se e solo se

$$b \leq p \leq e - \text{sizeof}(\text{typeof}(p))$$

Ogni puntatore ha un tipo, quindi “quanto si può spostare” è determinato anche dalla dimensione del tipo puntato (se è su int di 4 byte non posso puntare al penultimo byte, andrei fuori per gli ultimi 3). L'aritmetica sui puntatori modifica solo  $p$ , senza toccare  $b$  ed  $e$ ;  $p$  si sposta, gli altri due rimangono lì a stabilire i limiti. Deve sempre valere la disuguaglianza.

I Fat Pointers sono puntatori che hanno dati aggiuntivi, come la tripla descritta in precedenza; metadati aggiunti ai puntatori. Effettuare il controllo **ad ogni accesso** degrada le performance (soprattutto quando non è l'unico controllo da effettuare, questo è solo per la spatial safety). Il controllo è oneroso ed è necessaria una memoria aggiuntiva per i metadati legati ad ogni puntatore.

Il compilatore di un linguaggio memory safe deve istanziare memoria aggiuntiva per ogni puntatore e aggiungere il codice per i controlli, ad ogni accesso.

**Low Fat Pointers:** Si tratta di una variante che vuole ridurre l’overhead in termini di spazio e prestazioni. L’idea è quella di “codificare” all’interno dell’indirizzo stesso i metadati, la rappresentazione nativa del puntatore può inglobare i metadati. La disposizione della memoria viene usata per ricavare le informazioni prima salvate nei metadati in tempo costante.

La memoria virtuale viene divisa in “regioni”, ciascuna riservata ad oggetti di dimensioni simili. Questo consente di dedurre la dimensione di un oggetto basandosi solo sull’indirizzo del puntatore (se appartiene a quella regione deve avere una certa dimensione).

### 3.1.2 Temporal Safety

Le regioni di memoria possono essere:

- **definite:** allocate e attive
- **non definite:** non inizializzate, non allocate o deallocate

Quando un puntatore punta ad una zona di memoria non definita è un problema. Per evitare errori serve tener traccia di dove un puntatore punta all’interno delle regioni di memoria. Dobbiamo evitare dangling pointers.

Esempio:

```
1 p = malloc(4)
2 s = p
3 free(p)
```

**s** rimane dangling.

Serve una tabella di memoria per ogni puntatore che punta a tale zona. Quando la zona viene deallocata/diventa non definita, tutti i puntatori che fanno riferimento a quella zona devono essere resi non più validi. Nell’esempio precedente, **s** dovrebbe essere messo a **NULL** dopo la deallocazione. Questo richiede un controllo sulla validità del puntatore ad ogni dereferenziazione.

La combinazione di spatial e temporal safety si chiama **memory safety**. Il modo più semplice per ottenerla è utilizzare un linguaggio memory safe. C/C++ non sono memory safe, ma permettono di scrivere codice memory



safe, il problema è che *non ci sono garanzie*. Il compilatore potrebbe aggiungere codice per controllare le violazioni, ma rimane sempre il problema dell'inevitabile degrado delle performance (bisogna solo stabilire quanto e se questo è accettabile).

### 3.2 Type Safety

La type safety ha lo scopo di definire su che tipo di dato sono ammissibili quali operazioni, riducendo così le possibili problematiche durante l'esecuzione del programma.

Ogni oggetto ha un **tipo associato** (`int`, `int pointer`, `float`, ...). Una volta determinati i tipi, posso decidere **quali operazioni** sono ammissibili per **quali tipi**. Le operazioni fatte sugli oggetti devono *sempre* essere sempre compatibili con il tipo dell'oggetto, evitando errori, anche run-time.

In generale la type safety è *più forte della memory safety*. Esempio memory safe ma non type safe:

```
1 int (*cmp) (char*,char*);  
2 int *p = (int*) malloc(sizeof(int));  
3 *p = 1;  
4 cmp = (int (*)(char*,char*)) p; // Memory safe, not Type safe  
5 cmp("hello", "bye"); // crash!
```

In questo caso è memory safe in quanto abbiamo messo un valore “entro i limiti” all’interno del puntatore a funzione `cmp`, ma sta tentando di mettere un intero all’interno di un **type address** (al posto dell’indirizzo della funzione ho 1), quindi non è type safe (quindi crasha, `SEGFALT`). Se il tipo dei due valori è disallineato la type safety **nega l’assegnamento**.

C/C++ implementano tipi primitivi ma non c’è nessun controllo su *cosa viene assegnato a cosa*. Effettuare questi controlli può essere oneroso, vanno fatti su **ogni operazione** tra dati. In breve, la type safety costa performance, quindi, anche se ci sono soluzioni, non sempre hanno overhead accettabile.

**Dynamically Typed Languages:** All'interno dei linguaggi dynamically typed, tutti gli oggetti hanno **un solo tipo: dinamico**. Ogni operazione su un oggetto di tipo dinamico è permessa, ma tale operazione potrebbe non essere implementata, portando ad un'eccezione. Tutto è permesso, ma se run-time il tipo effettivo non implementa l'operazione viene sollevata un'eccezione.

**Enforce Invariants:** Gli invarianti sono delle **formule logiche** per garantire determinate proprietà sull'esecuzione di dei pezzi di codice, rimane costantemente vero in certi punti del programma. Possono essere fatti valere tramite type safety. Una proprietà che deve rimanere sempre vera durante l'esecuzione del programma.

**Types for security:** Gli invarianti possono essere usati anche per la sicurezza, generalmente riguardano il controllo del flusso di dati, prevenendo errori logici. Tale controllo del flusso di dati, anche all'interno dello stesso programma, permette di non “*far uscire*” un dato da determinate zone.

Esempio: Java with Information Flow (JIF), estensione di Java

```
int{Alice -> Bob} x;  
int{Alice -> Bob, Chuck} y;  
x = y;           //OK: policy on x is stronger  
y = x;           //BAD: policy on y is not as strong as x
```

### 3.3 Avoiding Exploitation: Other strategies

Sapendo che ogni attacco ha determinati prerequisiti, un modo per prevenirli è fare in modo che le condizioni non si possano presentare. Questo aumenta la complessità dell'attacco, rendendo l'exploit più difficile da sfruttare.

Quindi, tento di evitare bug, ma aggiungo protezioni nel caso qualcosa sfugga. Per evitare i bug esistono secure coding practices e tecniche di code review avanzate, come program analysis, fuzzing, ....

Per evitare l'exploitation, quali sono le fasi di un attacco di stack smashing?

- scrivere il codice dell'attaccante in una zona di memoria
- fare in modo che `%eip` esegua il codice dell'attaccante
- trovare il return address

Vogliamo inibire una di queste fasi.

Come si possono rendere più difficili questi attacchi? Il caso migliore è **modificare librerie, compilatore e/o sistema operativo**, in modo tale da non dover cambiare il codice dell'applicazione ma avere una soluzione a **livello architetturale**.

**Canary:** Per inibire la fase di overflow, ci si è ispirati ai canarini usati dalle miniere: se il canarino muore c'è gas. Possiamo fare una cosa simile per lo stack, scriviamo un valore prima del return address e se al termine dell'esecuzione della funzione (prima di fare il `ret`) il valore è non è quello definito all'inizio c'è stato un tentativo di stack smashing. Il valore originale va salvato in una zona di memoria safe, e read-only.

Come viene scelto il valore della canary:

- terminator canaries (`CR`, `LF`, `NUL`, `-1`): valori non ammessi dallo `scanf`, l'attaccante non li può inviare come input;
- numero random, scelto ad ogni inizio del processo;

- **Random XOR canaries:** si sceglie un valore random, ma il return address diventa  $\text{ret} := \text{ret} \oplus \text{canary}$ , tornando al valore originale al termine della funzione, “sabotando” un eventuale indirizzo di ritorno sovrascritto in quanto tornerà ad un valore casuale al posto che all’indirizzo segnato. Permette di risparmiare sullo stack lo spazio della canary.

**Data Execution Prevention DEP:** La seconda fase dell’attacco è scrivere in memoria il codice ed eseguirlo. Per evitare che codice dell’attaccante possa essere eseguito si possono **rendere alcune zone di memoria**, come stack e heap, **non eseguibili**. In questo modo, se anche viene bypassata la canary, il programma va in panico prima di eseguire codice posizionato nello stack/heap. Nelle zone solo dati non si può eseguire codice (generalmente, esistono casi particolari). Si chiama Data Execution Prevention, non posso iniettare codice eseguibile.

**Return-to-libc:** Metodo trovato per evadere la DEP, l’idea è inserire nel return address funzioni presenti all’interno della libreria di sistema, le quali sono ovviamente eseguibili. L’instruction vector sovrascrive il return address con l’indirizzo di una funzione di sistema, preparando lo stack con i parametri corretti per l’esecuzione di tale funzione. Modifico l’esecuzione del codice senza iniettarlo.

**Address Space Layout Randomization ASLR:** Randomizzare il layout di memoria, ogni volta che il processo va in memoria vengono usate zone di memoria differenti, ho un sacco di spazio, metto dove voglio il programma. In questo modo i valori esatti degli indirizzi di memoria sono sconosciuti, permette di inibire l’ultima fase di sovrascrittura del return address: se non so dove sia il mio codice non so dove far puntare il return address. Permette anche di evitare gli attacchi come **return-to-libc** randomizzando la posizione delle librerie di sistema.

Esistono diverse implementazione, ma in generale bisogna notare che:

- sposta solo l’offset delle zone di memoria, non le posizioni relative all’interno di essere
- potrebbe essere applicato solo alle librerie (sempre position independent), non al codice del programma (potrebbero esserci riferimenti

“statici” a zone del programma)

- servono abbastanza bit random, altrimenti si può fare brute-force (su architettura 32 bit non è sicuro, su 64 è già molto meglio)

## 4 Return Oriented Programming ROP

Prevenzione ed attacchi si “inseguono” sempre:

- **Difesa:** stack/heap non eseguibile per prevenire iniezione di codice; **attacco:** jump/return to libc
- **Difesa:** nascondere gli indirizzi di memoria e return address con ASLR; **attacco:** ricerca brute force (32 bit) o information leak (format string)
- **Difesa:** non usare codice in libc ma usare solo codice all’interno del text del programma, si riducono le funzioni di libreria legate all’utilizzo del processo stesso, vengono caricate solo le parti necessarie; **attacco:** costruire le funzionalità che servono tramite Return Oriented Programming ROP

Il Return Oriented Programming nasce dall’esigenza di limitare il numero di funzioni che un processo usa per la propria esecuzione. Introdotta per la prima volta nel 2007 da Hovav Shacham (*The Geometry of Innocent Flesh on the Bone: Return-into-libc without Function Calls*).

L’idea di base è: prendo pezzi di codice dalle funzioni presenti in memoria e le unisco per “costruire” un attacco, ovvero il programma voluto dall’attaccante. Si può dimostrare che, con una codebase sufficiente, gli elementi costruibili sono Turing-compatibili. I pezzi di codice usati si chiamano **gadget**. Si tratta di una nuova tecnica per eseguire codice sfruttando una vulnerabilità (sempre buffer overflow).

Le “sfide” di questo attacco sono

- trovare i gadget
- collegarli

Ma *cosa sono i gadget*? Si tratta di sequenze di istruzioni (assembly) che terminano con un **ret**. Si “trasforma” il processo di esecuzione (il programma diventa una **weird machine**), lo stack diventa il “codice” per l’attaccante; non si può iniettare codice all’interno dello stack ma nella weird machine descritta:

- **%esp** diventa (una sorta di) program counter
- i gadget sono invocati tramite una **ret** (si parte dalla prima, quella sovrascritta da un buffer overflow per esempio)

- i gadget hanno parametri, passati tramite lo stack, quindi tramite pop,  
...

Si ha una trasformazione della memoria del programma. L'idea è

- prendere il codice che vogliamo eseguire
- emulare l'assembly tramite i gadget

Concateno gadget trovati in memoria (pezzi di codice terminati da `ret`) per simulare il comportamento voluto. L'overflow del buffer termina sovrascrivendo l'indirizzo del primo gadget in memoria.

Esempio: volendo simulare il codice

```
mov %edx, 5
```

Avendo come gadget

```
pop %edx
ret
```

E il valore 5 sullo stack, possiamo fare in modo che il valore puntato da `%esp` sarà caricato in `%edx` ed `%esp` spostato sopra. Al termine di ogni gadget si ha il `ret`, fondamentale per concatenare i gadget. Cosa fa una `ret`? Prende il primo valore sullo stack (`pop` di cosa punta `%esp`) e continua da lì (codice puntato) l'esecuzione del programma. Quindi se sullo stack è presente il codice del prossimo gadget, l'esecuzione proseguirà da lì.

In altre parole: cambio l'indirizzo di ritorno con l'indirizzo del primo gadget, sullo stack ci sarà la chain di return address di gadget e parametri usati dagli stessi, ogni volta che ne viene eseguito uno (a partire dal primo), lo stack pointer scende e trova quello dopo.

Esistono tool automatici per automatizzare la ricerca e unione dei gadget, chiamati ROP Compiler.

Sequenza di codice	Equivalente ROP
0x17f: mov %eax, [%esp] mov %ebx, [%esp+8] mov [%ebx], %eax	0x17f: pop %eax ret ... 0x20f: pop %ebx ret ... 0x21a: mov [%ebx], %eax

Sostanzialmente, nello stack saranno presenti:

- indirizzo del gadget
- parametro/i del gadget
- indirizzo del gadget
- ...

Quindi devo sovrascrivere lo stack con un layout di questo tipo.

**Trovare i gadget:** I gadget per costruire un exploit possono essere trovati con una ricerca automatica del binario (cercando `ret` e andando a ritroso, esempio di `ROP gadget finder`).

Ma quanti gadget sono presenti? Ogni programma, in architettura Intel, può essere visto come  $n$  rappresentazioni diverse: dato che è un'architettura CISC le operazioni possono avere diverse lunghezze, quindi saltare in mezzo ad un'istruzione porta ad una codifica diversa. Esempio: se l'istruzione `a` ha opcode `0x0a0b` e l'istruzione `b` ha opcode più breve `0x0b`, "saltando" il primo byte dell'istruzione `a` ho effettivamente trovato un'istruzione `b`. In questo modo posso trovare `ret` o qualunque cosa in maniera più semplice. Diventa più difficile su architetture RISC (tutti i byte di istruzione sono allineati).

I gadget sono sempre sufficienti per portare avanti un attacco? Sì, Shacham ha provato che per code base non triviali (e.g., `libc`), i gadget sono Turing completi.

Un ROP Compiler prende in input:

- codice che voglio eseguire ad alto livello
- programma vittima

E restituisce in output l'injection vector, ovvero il layout dello stack per effettuare l'attacco (eseguire il codice input). Quindi prende il programma, definisce che gadget servono, li trova nel programma e crea il layout dello stack.



## 4.1 Blind ROP

Si tratta di un attacco pubblicato da stanford ([qui la pagina](#)) che mostra come il ROP si possa applicare in condizioni reali. Il contesto è:

- remoto, si tratta di un server nginx
- l'attaccante non ha il binario (programma eseguibile), nè il source code
- ASLR, canary, DEP attivi
- conoscenza di una vulnerabilità, da qualche parte

L'idea è: su un eseguibile PIE a 64 bit in esecuzione su un server, se in seguito ad un crash il server riparte ma non ri-randomizza i valori posso:

- leakare canary e return address dallo stack
- trovare gadget (run-time) per leakare il binario
- trovare i gadget per la shellcode

Lo scopo del programma è andare a leakare il binario, ovvero usare un gadget che va in memoria, prende il programma e lo restituisce all'attaccante. Per fare questo bisogna far fare al server una write su una socket `sd`, con buffer e relativa lunghezza, dove

- il buffer sarà l'indirizzo del programma, sconosciuto per ASLR
- la lunghezza sarà la dimensione dell'applicazione, approssimativamente nota

Dato che ad ogni connessione il server mantiene gli stessi valori (nuovo thread, stessi dati, fork), anche se poi il thread crasha, le fasi sono:

- leakare la canary
- defeat the ASLR
- trovare blind i gadget per fare una write
- ottenere il binario

**Leakare la canary:** Trovo la dimensione del buffer (tirando ad indovinare) e poi provo a sovrascrivere un byte della canary, provando tutti i valori finché non crasha per poi passare al byte successivo.

**Defeat the ASLR:** Provo ad indovinare il return address, similmente a come fatto per la canary, bisogna scoprire *più o meno* dov'è il programma; una volta conosciuta la canary posso tirare ad indovinare finché non scopro uno degli indirizzi dov'è posizionato il programma.

**Blind search:** Dobbiamo trovare in modo blind i gadget che permettano di fare la write. Per una `write(sd, buffer, length)` le istruzioni che servono sono

```
pop rdi //sd
pop rsi //buffer
pop rdx //length
pop rax //write syscall num
syscall
```

Quindi servono i gadget per fare

```
pop rdi; ret
pop rsi; ret
pop rdx; ret
pop rax; ret
syscall
```

Il `sd` si può indovinare (8 bit, facile), ma devo trovare questi gadget senza avere il binario. Per indovinare il gadget posso sfruttare la differenza di comportamento tra `pop` ed altre istruzioni: `pop` sposta il `esp`. Dopo aver trovato la canary si tira ad indovinare, sovrascrivendo il return address, per trovare due gadget:

- idle gadget: un indirizzo che mantiene aperta la socket
- stop gadget: un indirizzo che fa crashare la socket

I gadget reali si trovano sfruttando questi due: sullo stack metto, in ordine,

1. indirizzo del gadget cercato
2. stop gadget
3. idle gadget.

Provando ad eseguire, il gadget cercato può essere:

- un'istruzione normale (non **pop**): l'**esp** non viene spostato, il gadget eseguito dopo è lo stop e la socket crasha
- una **pop**: viene spostato l'**esp**, lo stop gadget non viene eseguito, la socket rimane aperta

In questo modo posso mappare i gadget in memoria a run-time, so dove ci sono le **pop**. Per capire su che registro viene fatta la **pop**: non lo capisco, si provano a caso le **pop** trovate e quando torna indietro qualcosa dalla socket ho beccato la combinazione giusta (ha fatto la write).

L'indirizzo per la write lo si trova tirando ad indovinare nella GOT.

## 5 Control Flow Integrity CFI

Si tratta di una tecnica di protezione basata su un'idea diversa dalle altre difese descritte precedentemente, le quali “complicavano” l'attacco prevenendone le fasi. Qua il paradigma di difesa è diverso, si vuole una cosa più generale, l'idea è **definire un modello di comportamento del programma** e se l'esecuzione esce da questo modello viene segnalata un'anomalia.

Le “sfide” di questa idea sono:

- definire il modello di comportamento, qual'è il comportamento aspettato
- rilevare efficientemente e velocemente deviazioni dalle aspettative
- evitare possibili compromissioni del detector/monitor che controlla il programma

**Definire expected behavior:** Come si può **caratterizzare il comportamento di un programma** durante l'esecuzione? Una caratteristica fondamentale di tutti i programmi è il control flow, rappresentabile tramite **Control Flow Graph CFG**, in cui ogni nodo è una chiamata a funzione (insiemi di istruzioni) e gli archi sono i passaggi di stato del programma. Il CFG rappresenta il flusso del programma in termini di insiemi di istruzioni e transizioni tra di essi.

Se durante l'esecuzione effettiva il comportamento non rispetta le transizioni definite: anomalia.

**Rilevare deviazioni efficientemente:** Il controllo deve essere rapido, quindi il monitor deve essere efficiente. Non può essere esterno perché diventerebbe troppo invasivo. Il controllo viene quindi inserito all'interno del programma: **In-line reference monitor IRM**, ci sono istruzioni di controllo inserite all'interno del programma stesso.

I controlli vanno fatti rispetto ad un **threat model** ben definito: si suppone quali siano le possibili azioni che l'attaccante può o non può compiere e i controlli vengono inseriti di conseguenza. Ad esempio: presuppongo che l'attaccante

- può fare stack e heap overflow, ROP
- non può disabilitare il IRM, non può modificare il codice in memoria (DEP)

Va sempre definito un threat model con ciò che è e non è lecito fare da parte dell'attaccante. Se l'attaccante riesce a rompere questi presupposti il sistema di difesa viene effettivamente superato (ad esempio, disabilita il IRM saltando i check).

**Evitare compromissione del detector:** Per evitare che il IRM venga disabilitato sicuramente serve che il codice sia immutabile e che sia presente una sufficiente randomness all'intero dei controlli stessi. L'in-line monitor deve essere protetto da immutabilità e randomness.

In termini di **efficienza**: il **Classic CFI** (2005 di Microsoft Research) portava un overhead medio del 16%, con 45% nel caso peggiore; funzionava solo su eseguibile, non sulle librerie. Nel 2014 si è raggiunto il **Modular CFI** ([pagina autore](#)), un modello di CFI modulare con un overhead molto più basso (5% in media, 12% worst case), il quale è in grado di lavorare anche su librerie.

**Sicurezza:** MCFI permette di ridurre del 95.75% i gadget ROP; definendo punti di entrata ed uscita dell'esecuzione non si può portare avanti un attacco ROP, il quale, per definizione, modifica il flusso del programma; MCFI blocca i salti illeciti.

La percentuale di riduzione viene dal fatto che i gadget non possono essere utilizzati in quanto non parte del flusso di controllo originale. Viene significativamente ridotta la superficie di attacco, si possono usare solo i gadget presenti all'interno del flusso di esecuzione (pochi).

Un'altra metrica usata è l'**Average Indirect-target Reduction (AIR)**, ovvero la percentuale di riduzione di possibili bersagli di salti indiretti che un attacco potrebbe sfruttare (punti di controllo del control flow). Le istruzioni di salto possono essere categorizzate in

- **direct calls:** viene definito esplicitamente l'indirizzo a cui saltare (direct, salta a quell'indirizzo)
- **indirect calls:** tutte le operazioni in cui l'indirizzo finale del salto va calcolato a runtime

In sostanza, la percentuale di bersagli per salti indiretti che vengono eliminati dalla CFI, ovvero quasi tutti.

## 5.1 Costruzione del Control Flow

La costruzione del control flow di un programma è divisa in due fasi:

- analisi statica
- analisi dinamica


**Analisi statica:** Il compiler costruisce il grafo del control flow (già presente, viene usato per ottimizzazione, “strumenta” il programma).

Il primo passo dell'analisi statica è il **call graph**, ovvero il grafo che rappresenta le chiamate a funzione, quale funzione chiama cosa. Esempio:

```
sort2(int a[], int b[], int len)
{
    sort(a, len, lt);
    sort(b, len, gt);
}


bool lt(int x, int y) {
    return x<y;
}

bool gt(int x, int y) {
    return x>y;
}
```



Permette di rappresentare il **flusso di chiamate** all'interno del control flow, ma si tratta di un modello piuttosto permissivo: rappresenta le chiamate ma non il flusso reale delle funzioni.

Idealmente vorremmo un modello più restrittivo, ovvero il CFG; si introducono i **basic blocks**: dei contenitori di istruzioni sequenziali terminate da un'istruzione di salto, di qualsiasi tipo (`jmp`, `ret`, ...). Permette di distinguere `call` dai `return`, il grafo sul codice di prima diventa:



Ogni funzione viene “spezzata” in moduli, ognuna delle quali ha una call/return, definendo meglio il modello di esecuzione del programma. Ogni basic block fa una call o una return (praticamente un gadget).

In sostanza:

- viene calcolato il CFG di call/return a compile time (o comunque partendo dal binario)
- il control flow del programma viene monitorato dall'interno, assicurando che segua percorsi definiti dal CFG
- le direct calls non vanno monitorate (assumendo che il codice sia immutabile, l'indirizzo target non può essere cambiato), quindi **solo le indirect calls vanno controllate** (`jmp`, `call`, `ret` con target non costanti, tutti i salti parametrici)

## 5.2 In-Line Monitor

Bisogna implementare all'interno del programma un metodo efficace per controllare “da dove arriva” un salto, inoltre deve essere una “trasformazione” del programma. Per fare ciò vengono usate delle **label**:

- viene inserita una label all'inizio del basic block destinazione del salto, come commento, riga non di codice
- prima di saltare, viene fatta una **cmp** tra il valore presente nella destinazione (dove punta il registro su cui viene fatto il salto) e il valore che dovrebbe avere la label
- se coincidono tutto a posto, manda avanti l'esecuzione
- se non coincidono blocca il programma

Il codice

Source			Destination		
Opcode bytes	Instructions		Opcode bytes	Instructions	
FF E1	jmp ecx	; computed jump	8B 44 24 04	mov eax, [esp+4]	; dst
...					

Diventa:

Source			Destination		
Opcode bytes	Instructions		Opcode bytes	Instructions	
81 39 78 56 34 12	cmp [ecx], 12345678h	; comp ID & dst	78 56 34 12	data 12345678h	; ID
75 13	jne _error_label	; if ≠ fail	8B 44 24 04	mov eax, [esp+4]	; dst
8D 49 04	lea ecx, [ecx+4]	; skip ID at dst	...		
FF E1	jmp ecx	; jump to dst			

Viene inserita una label per ogni basic block, quando c'è un indirect call il programma controlla che la destinazione abbia la label corretta (o una delle label corrette) prima di saltare. Controlla che il salto sia alla destinazione corretta.



**Tipi di labeling:** Il **labeling** può essere:

- **semplice:** una stessa label per tutti i blocchi; evita chiamate fuori dal grafo ma non impedisce salti errati; permette “quello che vuoi” all’interno del grafo
- **dettagliato:** una label diversa a seconda dei punti di ritorno, permettendo di controllare anche che i salti all’interno del grafo siano corretti

**Can we defeat CFI?**

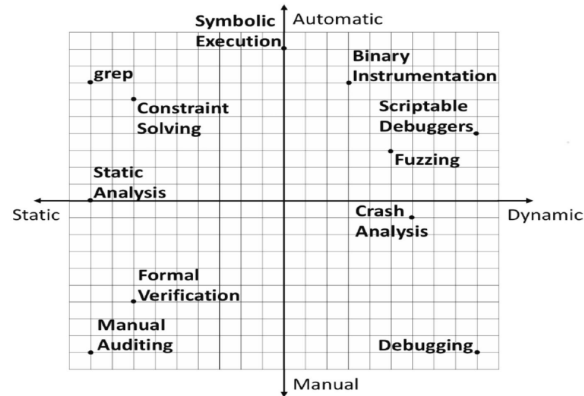
- Code injection con label corretti: non si può fare perché i dati non sono eseguibili (DEP)
- Modificare label nel codice per permettere il control flow desiderato: il codice è immutabile
- Modificare lo stack durante il check per controllarne l’esito: l’attaccante non può modificare i registri in cui sono caricati i dati rilevanti al controllo (No time-of-check, time-of-use bug TOCTOU)

**Garanzie:** Il CFI garantisce di impedire attacchi che modificano il control flow (ROP, ret2libc, ...). Ma non

- attacchi che manipolano il control flow seguendo le label (mimicry attacks, soprattutto con labeling semplice)
- data leaks: hearthbleed non sarebbe stato bloccato
- corruptions: modificare variabili di controllo per portare al flusso di esecuzione desiderato (es: overflow di una variabile “**authenticated**” su cui viene fatto un controllo)

## 6 Vulnerabilities Detection

Dato un programma, si vuole cercare in modo proattivo se sono presenti vulnerabilità. Esistono molti metodi per cercare vulnerabilità, che possono essere più o meno automatici e possono operare in maniera statica o dinamica.



Di conseguenza, una tecnica può essere

- Dinamica e automatica, esempio: binary instrumentation (inserire codice a runtime) o fuzzing (inviare input con l'obiettivo di trovare comportamenti anomali)
- Dinamica e manuale, esempio: debugging (eseguire il programma passo-passo per osservarne lo stato interno)
- Statica e manuale, esempio: manual auditing del codice (revisione manuale), verifica formale (dimostrare matematicamente la correttezza)
- Statica e automatica, esempio: analisi statica, esecuzione simbolica

Prima di effettuare le analisi è necessario definire delle proprietà attribuibili ai tool usati per effettuare le analisi. Le proprietà principalmente sono:

- **Soundness:** una tecnica è *sound* se è in grado di dire che un programma non ha nessuna vulnerabilità, ovvero se c'è una vulnerabilità la trova. Possono esserci **falsi positivi** (si tratta di un'approssimazione astratta), ma se è presente una vulnerabilità vera la trova. Di conseguenza, un programma è *unsound* se ci sono dei falsi negativi
- **Completeness:** una tecnica è *complete* se, quando una vulnerabil-

ità viene trovata, questa è vera. Può offrire **falsi negativi**, ovvero “mancare” vulnerabilità, ma se la trova è sicuramente una vulnerabilità reale. Di conseguenza, una tecnica incomplete può avere falsi positivi

**TL;DR:** Le tecniche possono essere **sound**: trova tutti i bug possibili, potrebbe essere un falso positivo, oppure **complete**: può non trovare tutti i bug, ma se lo trova è una vulnerabilità reale. Ovviamente non esiste un tool che le ha entrambe.

Da queste proprietà si possono derivare altre caratteristiche, ad esempio:

- se un tool è sound allora vuol dire che considera tutti i path di esecuzione possibili del programma, in quanto requisito per trovare tutti i bug possibili; in maniera dinamica questo non è fattibile, viene fatto tramite tecniche di static analysis, costruendo un’astrazione dell’esecuzione del programma
- se un tool è complete allora deve mostrare esecuzioni del programma che permettono di verificare le vulnerabilità; quindi l’analisi è più dinamica, il programma viene lanciato con un set di input che possono causare problemi; la tecnica fornisce input concreti che triggerano vulnerabilità

La soundness è più legata alla static analys, mentre la completeness alla dynamic analysis.

La **static analysis** consiste generalmente di modelli matematici astratti per l’esecuzione del programma per poi fare inferenza su quali possibili path potrebbero portare a vulnerabilità. La **dynamic analysis** invece utilizza esecuzioni più concrete per mostrare vulnerabilità effettive. Solitamente, i tool di detection hanno un approccio ibrido, usando tecniche statiche e dinamiche per ottenere un buon compromesso tra soundness e completeness. Il trade off si traduce in quanti falsi positivi e falsi negativi saranno presenti.

Una differenza importante tra static e dynamic execution sono le performance: la static analysis è una analisi del codice, di conseguenza è molto più veloce dell’esecuzione vera e propria del programma (la dynamic deve eseguire davvero il programma, quindi può essere molto lenta).

## 6.1 Symbolic Execution

La static analysis è una analisi off-line a partire da codice sorgente o binario del programma, quindi produce risultati riguardo la qualità del codice. Vengono definite delle proprietà a priori sul codice e i tool di static analysis controllano che queste vengano rispettate.

Un classico esempio di analisi statica è il compilatore di un programma: per la compilazione e ottimizzazione bisogna effettuare un'analisi del codice; molti tool di analisi statica si basano su ciò che produce il compilatore. L'analisi statica può usare o meno l'esecuzione simbolica.

La symbolic execution è una tecnica di static analysis che permette di eseguire in maniera off-line un'esecuzione del programma, “finge” un'esecuzione del programma. Si chiama “simbolica” perché vengono usati valori simbolici, viene calcolata un'approssimazione del programma per ottenere formule che rappresentano lo stato del programma in diversi punti di esecuzione.

Il testing funziona: i bug riportati sono reali, ma ogni test è sostanzialmente un'asserzione, ogni condizione di test può controllare solo una possibile esecuzione. In breve, complete but not sound. Si spera che il caso di test generalizzi abbastanza, ma non ci sono garanzie.

La symbolic execution generalizza quello che è il testing di casi singoli, vuole essere “più sound”, rappresentando più in generale l'esecuzione del programma. Da asserzioni su input concreti passa ad asserzioni su simboli generici, esempio:

```
assert(f(3) == 5)  $\longrightarrow$  y = a; assert(f(y) == 2*y-1);
```

Se il path di esecuzione dipende da variabili sconosciute, l'esecuzione simbolica viene divisa concettualmente

```
int f(int x) if (x > 0) then return 2*x - 1; else return 10;
```

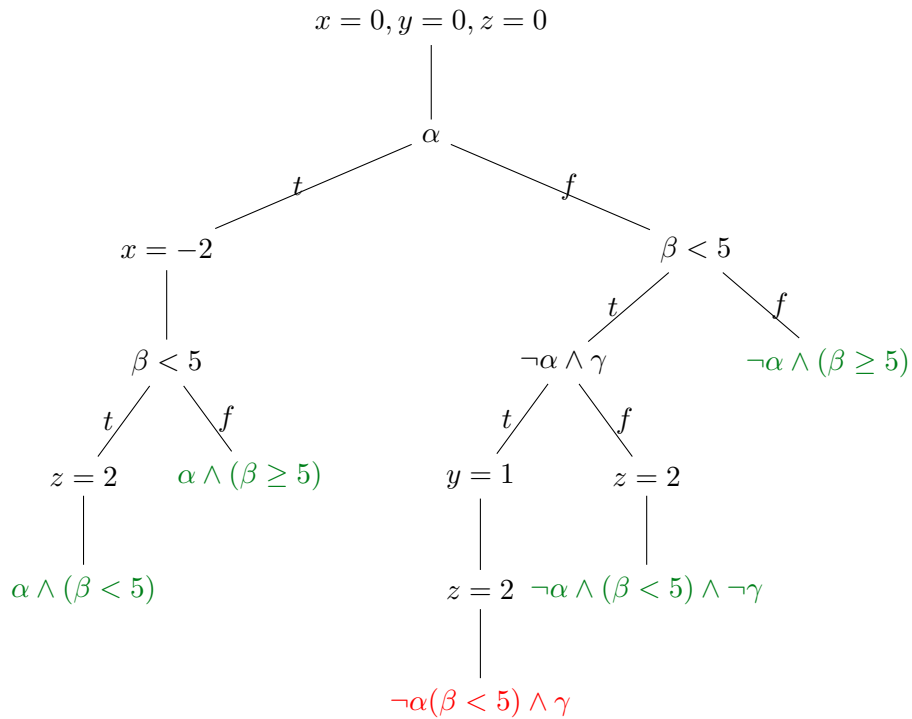
Una “esecuzione simbolica parallela”.

Esempio:

```

1  int a = alpha, b = beta, c = gamma; // symbolic!
2  int x = 0, y = 0, z = 0;
3  if (a) {
4      x = -2;
5  }
6  if (b < 5) {
7      if (!a && c) { y = 1; }
8      z = 2;
9  }
10 assert(x+y+z != 3)

```



Non voglio eseguire realmente il programma, ma si vuole verificare che non ci possa mai essere un'esecuzione del programma che viola determinate proprietà. Voglio vedere se esiste una classe di input che permette di violare le condizioni di esecuzione del programma.

Per ogni terminazione di path di esecuzione sarà presente una **path condition**: una formula che permette di individuare tutti gli input che permettono di eseguire quel determinato path (nell'esempio: in verde se soddisfacenti, rosse altrimenti); se tutte le condizioni sono verificate (e quindi l'equazione logica è risolta) vuol dire che gli input permettono di entrare in quel determinato path di esecuzione.

Ogni foglia dell'albero di esecuzione ha legata la sua equazione logica che permette di stabilire i potenziali input che portano l'esecuzione in quel determinato path.

Se trovo una violazione delle asserzioni in un determinato path, risolvendo la path condition ottengo la classe di input che causa la violazione dell'asserzione. Dalla formula si può derivare l'input concreto per la violazione. Trovare input per la violazione diventa problema per un **constraint solver** (come ad esempio Z3).

Ogni path dell'esecuzione simbolica rappresenta più esecuzioni del programma: esattamente il set di esecuzioni i cui valori concreti soddisfano la path condition. In questo modo si possono coprire molte parti di esecuzione e testing.

Vista come analisi statica, la symbolic execution è

- **complete**, ma **non sound** (generalmente non termina, si “incastra” spesso, la terminazione non è garantita)
- dipendente da path, flow e contesto

L'idea è piuttosto vecchia, ma aveva dei limiti che la rendevano poco pratica, in particolare: può essere molto compute-intensive: i path possibili possono essere *tanti*, con path condition lunghe e difficili da verificare (anche solo la soddisfacentità); quindi soggetta all'hardware del tempo: ad oggi hardware e algoritmi per i SMT/SAT solver sono molto migliorati.

Nel 2005-2006 è stata ripresa l'idea di symbolic execution per l'ambito del bug finding, con l'aggiunta di euristiche per ridurre lo spazio di esecuzione.

**Symbolic variables:** All'interno delle espressioni (quindi all'interno del linguaggio) vengono **aggiunte variabili simboliche**, le quali rappresentano valori sconosciuti. Vengono introdotte quando sono presenti input forniti al programma (`mmap`, `read`, `write`, ...). Se un bug viene trovato queste permettono di riprodurlo. Sono dei “placeholder” per valori sconosciuti a compile time (noti solo durante l'esecuzione).

Vogliamo fare in modo che il linguaggio possa includere espressioni simboliche. Normalmente, le variabili in un programma contengono valori, ora possono contenere anche espressioni simboliche.

Esempio:

```
1 x = read();
2 y = 5 + x;
3 z = 7 + y;
4 a[z] = 1;
```

La memoria simbolica conterrà:

$$\begin{array}{ll} \mathbf{x} & \mapsto \alpha \\ \mathbf{y} & \mapsto 5+\alpha \\ \mathbf{z} & \mapsto 12+\alpha \end{array}$$

E se `a` non è abbastanza grande, il valore di  $\alpha$  potrebbe causare problemi.

Il **controllo del programma** può essere **condizionato dai valori simbolici** (il programma dipende anche dai valori esterni, generalmente). Esempio:

```
1 x = read();
2 if (x>5) {
3     y = 6;
4     if (x<3)
5         y = 5;
6 }
7 else
8     y = 0;
```

E possiamo rappresentare l'influenza dei valori simbolici attraverso le path conditions. Esempio: l'esecuzione arriva alla riga 3 solo se la path condition  $\pi = \alpha > 5$ , mentre alla riga 5 si arriva solo se  $\pi = \alpha > 5 \wedge \alpha < 10$ .

Una path condition può essere insoddisfacibile: **unfeasible path** (non c'è soluzione alla formula logica). Le soluzioni a path constraints possono essere usate come input concreti.

Si possono introdurre asserzioni che permettono di determinare se ci sono vulnerabilità sfruttando la feasibility dei path. Esempio: prima di accedere ad un array si introducono dei bound check:

```
1  x = read();
2  y = 5 + x;
3  z = 7 + y;
4  if(z < 0)
5      abort();
6  if(z >= len(a));
7      abort();
8  a[z] = 1;
```

Le due condizioni permettono di controllare non ci siano buffer overflow all'interno del programma. Trovare delle soluzioni alle path condition rilevanti (nell'esempio, per la riga 5  $\pi = 12 + \alpha < 0$  e 7  $\pi = \neg(12 + \alpha < 0) \wedge 12 + \alpha \geq 4$ ) vuol dire trovare classi di input che permettono di avere la vulnerabilità per cui si sta testando (buffer overflow in questo caso).

Ogni volta che si presenta un branch si ha una fork dell'esecuzione simbolica: si ha un symbolic executor per ogni path di esecuzione. Accade quando si possono avere soluzioni sia alla path condition che alla sua negazione.

**Libraries e codice nativo:** L'esecuzione simbolica prima o poi raggiungerà i “limiti” dell'applicazione: librerie, sistema o chiamate a codice assembly. Le soluzioni a questo problema possono essere:

- far entrare il symbolic executor nella libreria, ma potrebbero essere *molto* complicate (probabilmente si incastrerà)
- fornire un modello delle librerie per l'esecuzione



### 6.1.1 Concolic Execution

Anche chiamata **dynamic symbolic execution**, il nome viene da concrete+symbolic. Lavora con gli stessi concetti della symbolic execution ma è un ibrido tra analisi statica e dinamica.

Si instrumenta il programma per fare symbolic execution durante l'esecuzione: a partire da un input concreto si esegue il programma, ma si traccia l'esecuzione simbolica durante l'esecuzione concreta; si tiene traccia delle path condition (shadow memory). Ogni volta che si trova un ramo condizionale nel flusso di controllo si tiene traccia del ramo percorso concretamente e la condizione per percorrerlo.

Terminata l'esecuzione di un percorso, si ottiene una path condition “completa”, per generare un percorso alternativo da eseguire si nega una delle condizioni e si usa un constraint solver per trovare un nuovo input che soddisfa tali condizioni.

Si esplora un percorso alla volta tramite valori concreti. Permette di avere sempre dei valori concreti per ogni esecuzione e si possono anche seguire chiamate esterne al programma (perdendo symbolic-ness). Si possono gestire casi senza necessariamente far esplodere la complessità per il SMT solver.

## 7 Fuzz Testing

Il **fuzzing** rientra tra le tecniche di ricerca di vulnerabilità. Nella sua forma più semplice consiste nell’inviare una elevata quantità di input automaticamente generati ad un target (programma o meno, qualsiasi cosa si debba testare); l’obiettivo della ricerca è **trovare stati invalidi** del programma. Per esempio, su un binario, il fuzzing genera input fino a far crashare il programma.

Ci sono diverse **tipologie di fuzzer**, si possono categorizzare per due elementi fondamentali:

- il metodo di generazione dell’input
- introspection: livello di conoscenza del programma

**Introspection:** Si possono avere 3 livelli principali:

- **black box:** non sanno nulla di come è formato il programma all’interno
- **white box:** conoscenza completa del programma, visione totale dello stato interno del programma
- **grey box:** non hanno una visione completa dello stato, ma possono estrarre informazioni a runtime tramite strumentazione

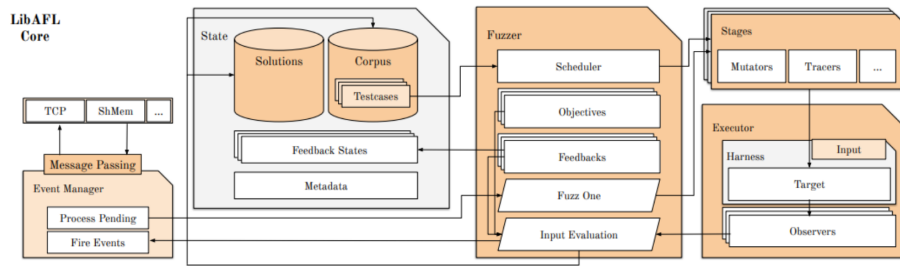
**Metodo generazione input:** Esistono fuzzer che hanno una generazione dell’input di tipo:

- **generazionale:** partono da zero, generano secondo una grammatica, espressioni regolari o regole più complesse (online learning, ML)
- **mutazionali:** viene fornito un set di input di partenza, ad ogni iterazione il fuzzer muta il set di input alla ricerca di altri input “*interessanti*” (va definito cosa significa)
- **ibrido:** combina tecniche di generazione e mutazione

## 7.1 Fuzzer Architecture

*Come è fatto un fuzzer?* Nella forma più semplice si hanno da un lato il fuzzer, il programma dall'altro: vengono mandati input da una parte all'altra.

**LibAFL:** Libreria Rust che permette la creazione di fuzzer arbitrariamente complessi. Per andare un po più nel dettaglio



**Executor:** Si tratta del componente che **riceve l'input** da parte del fuzzer vero e proprio **per poi eseguirlo**. Si possono avere diversi livelli di complessità per un executor, il più semplice (per un binario) è un fork server (fork del processo per poi applicare l'input, la fork evita di dover ricaricare il programma in memoria, il che sarebbe troppo lento). Altre tipologie di executor, ad esempio per un kernel, dato che non si può caricare un kernel ex novo ad ogni test, si usano VM o Hypervisor (wrapper attorno all'executor vero e proprio).

**Input:** Rappresentazione astratta della **tipologia di input accettata** dal programma. Potrebbe essere una bytestring (binario), una sequenza di syscall (kernel), una lista di transazioni (smart contract), ...; a seconda di ciò che viene testato è importante conoscere cosa prende in input il programma.

**Corpus:** Gli input vanno salvati da qualche parte. Il Corpus contiene due elementi:

- **Solutions:** input che assolvono al loro compito; ovvero causano crash/raggiungono l'obiettivo
- **Interesting:** input che raggiungono zone *interessanti* del programma (e quindi vengono messi in coda per eventuale mutazione)

Quelle non interessanti vengono scartate.

**Generator:** Il componente che si occupa di generare input, secondo grammatiche o regole di generazione. In generale, gli input generati devono rispettare una struttura.

**Scheduler:** Si può avere un numero indefinito di test case (tra generazione e mutazione gli input aumentano molto in fretta), quindi è importante orchestrare in maniera corretta la **selezione dei test case**. Va definito uno scheduler, nel caso più semplice può essere una coda/stack, ma può avere un impatto significativo sulle performance.

**Stage:** Definisce una serie di operazioni da effettuare sull'input (ricevuto dallo scheduler), come mutazioni, taint tracking, ....

**Mutator:** Si occupa della **mutazione degli input**. A seconda del test case e di ciò che si vuole ottenere ne esistono di diverso tipo, il metodo più semplice è un bit flip, ma anche splicing, block swapping, truncating, ...; possono essere usate tecniche arbitrariamente complesse.

**Observer:** Si vuole avere conoscenza di ciò che accade all'interno del programma, al fine di definire *cosa è interessante* (tranne nei casi di fuzzer black box, dove non si ha la nozione di interessante, vanno più o meno a caso, le uniche cose interessanti sono le soluzioni). L'observer si occupa di **estrarre** (in qualche modo) **informazioni dal programma** in fase di analisi per poi rimandarle al fuzzer.

Un esempio potrebbe essere una coverage map: controlla gli edge, vengono tracciati i possibili flussi di esecuzione e si tiene traccia in un bytearray di quante volte l'esecuzione passa attraverso ogni determinata zona del programma.

**Instrumentation:** Come si fa ad implementare un observer? Vogliamo estrarre informazioni da un programma a runtime, solitamente si fa con tecniche di **instrumentazione**: solitamente a partire da una intermediate representation (per poterlo analizzare più facilmente in maniera automatica, senza rischiare di modificare il comportamento originario del programma), si analizza il programma per identificare zone del programma interessanti e vengono aggiunte istruzioni che permettono di capire quando vengono raggiunte.

Esempio: mi interessa (per qualche motivo) contare le chiamate di sistema del programma, cerco all'interno della intermediate representation ogni volta che viene fatta una syscall e assegno un ID ad ognuna di queste, il codice iniettato tramite instrumentazione incrementerà in un array la casella corrispondente alla syscall effettuata, per ogni chiamata all'interno del programma. Altro esempio di instrumentazione: i fat pointer, obiettivo diverso, ma sostanzialmente è la stessa cosa (visti qui: 3.1.1).

TL;DR: instrumentazione vuol dire modificare il binario (solitamente non da sorgente, ma da rappresentazione intermedia), per rilasciare informazioni a runtime.

**Feedback:** Modulo che si occupa di **analizzare le informazioni estratte**, controparte dell'observer. Riceve l'output dell'observer, lo analizza per determinare caratteristiche riguardo al test case eseguito, ad esempio per stabilire se è interessante e aggiungerlo o meno al corpus.

Cosa manca? Altri componenti che potrebbero esserci, meno nel dettaglio:

- se il fuzzer è su una macchina diversa dall'eseguibile, bisogna collegarlo alla rete
- **Harness**: sotto-componente dell'executor che effettivamente passa l'input al programma

### 7.1.1 Sanitizers

Vogliamo identificare crash del programma, ma potrebbe non bastare per trovare vulnerabilità. Per questo motivo sono nati i sanitizer, pezzi di codice, **strumentazioni aggiuntive** che permettono di **rilevare comportamenti anomali** quando accadono. Esempi:

- **AddressSanitizer (ASan)**, rileva errori di memoria
- **UndefinedBehaviorSanitizer (UBSan)**, rileva undefined behavior
- **ThreadSanitizer (TSan)**, rileva race conditions

Quando rilevano un'anomalia fanno crashare il programma, con un log relativo all'errore, il quale può essere più o meno dettagliato.

Esempio: ASan (tra le altre cose) aggiunge delle “red zone” attorno alle zone di memoria, ovvero zone senza permessi di lettura o scrittura: quando il programma prova ad accedervi si genera un **segfault**. Instrumenta il programma per cercare tutte le allocazioni, tutti gli utilizzi della memoria in generale (con le relative ottimizzazioni, non così semplice).

Ovviamente non vengono usati in produzione, non si tratta di un comportamento desiderato, oltre al fatto che rallentano l'esecuzione.

## Notes

**State of the Art: AFL++:** Stato dell'arte per fuzzing su binario, presentato nel 2020 come gray box fuzzer con edge coverage guidance, derivato dall'originale AFL. Abbastanza customizzabile, scritto in C++.

**NB:** Si può fuzzare un po' tutto, non solo binari. Ad esempio:

- **Syzkaller:** unsupervised coverage-guided kernel fuzzer
- **Smartian:** Smart Contract Fuzzing with static and dynamic data-flow analyses
- **Nyx-Net:** coverage-guided network testing

**OSS-Fuzz:** Progetto lanciato da Google nel 2016 per fare fuzzing di repo open source di grossi progetti, individuando un buon numero di vulnerabilità in più di 1000 progetti.